

Session 11

Introduction to NLP Text Preprocessing

Python | RegEx | Zahra Amini

Telegram: @zahraamini_ai & Instagram:@zahraamini_ai & LinkedIn: @zahraamini-ai

<https://zil.ink/zahraamini>

Regular
Expressions
چیست؟

کاراکترهای پایه

یک رشته متنی هستند که از الگوهای خاصی تشکیل شده‌اند و برای جستجو و یافتن الگوها در متن استفاده می‌شوند. به عنوان مثال، می‌توانیم با استفاده از یک الگوی ساده، اعداد، حروف بزرگ، یا کلمات خاص را در یک متن پیدا کنیم

1. `.` (نقطه): این کاراکتر با هر کاراکتر تکی مطابقت دارد (به جز کاراکتر خط جدید).
- مثال: الگوی `a.b` هر کلمه‌ای که با حرف `a` شروع شود، یک کاراکتر دلخواه در وسط داشته باشد و با `b` پایان یابد را پیدا می‌کند؛ مانند `"acb"` و `"a1b"`.
2. `^` (علامت شروع): برای مشخص کردن شروع خط یا رشته استفاده می‌شود.
- مثال: الگوی `Hello^` رشته‌هایی که با `"Hello"` شروع می‌شوند را پیدا می‌کند.
3. `$` (علامت پایان): برای مشخص کردن پایان خط یا رشته استفاده می‌شود.
- مثال: الگوی `$world` رشته‌هایی که با `"world"` به پایان می‌رسند را پیدا می‌کند.
4. `*` (ستاره): به معنای صفر یا بیشتر از وقوع یک الگو است.
- مثال: الگوی `*a` تمامی جاهایی که دارای هیچ یا چندین حرف `a` هستند را پیدا می‌کند، حتی اگر `a` وجود نداشته باشد.

کاراکترهای پایه

5. $+$ (بعلاوه): به معنای یک یا بیشتر از وقوع یک الگو است.
- مثال: الگوی $a+$ هر جا که حداقل یک حرف a باشد را پیدا می‌کند.
6. $?$ (علامت سوال): به معنای صفر یا یک بار وقوع یک الگو است.
- مثال: الگوی $a?$ هر جا که حاوی یک یا هیچ حرف a باشد را پیدا می‌کند.
7. $\{n\}$ (براکت‌ها): برای مشخص کردن تعداد دقیق تکرار یک الگو استفاده می‌شود.
- مثال: الگوی $a\{3\}$ هر جایی که سه بار حرف a تکرار شده باشد را پیدا می‌کند.
8. $[]$ (براکت‌ها): برای تعریف یک مجموعه از کاراکترها استفاده می‌شود.
- مثال: الگوی $[a-z]$ تمامی حروف کوچک انگلیسی را شامل می‌شود.
9. $()$ (پرانتزها): برای گروه‌بندی کردن بخشی از الگو استفاده می‌شود.
- مثال: الگوی $+(ab)$ هر جا که حداقل یک بار توالی "ab" تکرار شود را پیدا می‌کند.

قواعد نوشتن یک
الگو با مثال

Example number: +1 (202) 555-1234

Our regex pattern: `\+?\d{1,3}?[-.\s]?(?:\d{1,4}?\\)?[-.\s]?d{1,4}[-.\s]?d{1,9}`1. `\+?`

- **Purpose:** Match the `+` sign, which often appears as a country code indicator.
- **Explanation:** `\+` matches the `+` character, and `?` means it is optional (can appear 0 or 1 time).
- **Application to the example:** In our example, the `+` sign is present at the beginning, so this part matches the `+`.
- **Match:** `+`

2. `\d{1,3}?`

- **Purpose:** Capture the country code or prefix, which typically has 1 to 3 digits.
- **Explanation:** `\d` matches any digit, and `{1,3}` means it can have between 1 and 3 digits. The `?` after `{1,3}` makes it non-greedy, meaning it will match the minimum digits required.
- **Application to the example:** The number `1` follows the `+`, which matches this part of the pattern.
- **Match:** `1`

Example number: +1 (202) 555-1234

Our regex pattern: `\+?\d{1,3}?[-.\s]?(?:\d{1,4}?)?[-.\s]?\d{1,4}[-.\s]?\d{1,9}`

3. `[-.\s]?`

- **Purpose:** Identify separators (like dashes, dots, or spaces) between parts of the phone number.
- **Explanation:** `[-.\s]` matches a dash `-`, dot `.`, or whitespace `\s`, and the `?` makes this optional.
- **Application to the example:** After the `1`, there is a space, so this part matches the space separator.
- **Match:** (space)

Example number: +1 (202) 555-1234

Our regex pattern: `\+?\d{1,3}?[-.\s]?\(?\d{1,4}?\)?[-.\s]?\d{1,4}[-.\s]?\d{1,9}`

4. `\(?\d{1,4}?\)?`

- **Purpose:** Match the area code, which may be enclosed in parentheses.
- **Explanation:**
 - `\(?` optionally matches an opening parenthesis `(`.
 - `\d{1,4}` matches between 1 and 4 digits (for area codes or part of the main number).
 - `\)?` optionally matches a closing parenthesis `)`.
- **Application to the example:** The area code `(202)` matches this part, including the parentheses and the digits inside.
- **Match:** `(202)`

Example number: +1 (202) 555-1234

Our regex pattern: `\+?\d{1,3}?[-.\s]?(?:\d{1,4}?)?[-.\s]?\d{1,4}[-.\s]?\d{1,9}`

5. `[-.\s]?`

- **Purpose:** Another separator between sections of the phone number, similar to step 3.
- **Explanation:** As in step 3, `[-.\s]` captures a dash, dot, or space, and `?` makes it optional.
- **Application to the example:** There is a space following `(202)`, so this part matches the space.
- **Match:** `(space)`

6. `\d{1,4}`

- **Purpose:** Match the middle part of the phone number, which may contain 1 to 4 digits.
- **Explanation:** `\d{1,4}` matches between 1 and 4 digits.
- **Application to the example:** The next section of the phone number is `555`, which matches this part of the pattern.
- **Match:** `555`

Example number: +1 (202) 555-1234

Our regex pattern: `\+?\d{1,3}?[-.\s]?(?:\d{1,4}?)?[-.\s]?\d{1,4}[-.\s]?\d{1,9}`

7. `[-.\s]?`

- **Purpose:** Another separator between sections, similar to previous steps.
- **Explanation:** This matches a dash, dot, or space, and is optional.
- **Application to the example:** In the example, a dash `-` follows `555`, matching this part.
- **Match:** `-`

8. `\d{1,9}`

- **Purpose:** Match the final part of the phone number, which can contain between 1 and 9 digits.
- **Explanation:** `\d{1,9}` matches between 1 and 9 digits, covering the last section of the number.
- **Application to the example:** The number `1234` matches this last part of the pattern.
- **Match:** `1234`